

# 文本生成图像任务中的强化学习框架调研报告

## 1 引言

近年来，文本生成图像（Text-to-Image, T2I）任务随着大规模扩散模型（Diffusion Models）的发展取得了显著进展。代表性工作包括 Stable Diffusion、Imagen 和 Parti 等。这些模型能够根据自然语言 prompt 生成高分辨率图像，在艺术创作、广告、游戏、虚拟现实等领域展现了广泛的应用前景。然而，传统的文本到图像生成大多依赖有监督学习（supervised learning）与对比学习（contrastive learning）。这种范式存在两个主要问题：

与人类偏好不一致：模型生成的图像虽然在像素分布上逼真，但可能不符合用户的审美或语义需求。

缺乏可控性（controllability）：模型往往难以遵循用户指令进行细粒度的控制（如物体数量、风格一致性）。

在自然语言处理领域，强化学习（RL）+人类反馈（Human Feedback）已被证明能够显著改善模型与人类偏好的对齐，如 OpenAI 的 InstructGPT。这一思路逐渐被引入到文本生成图像任务中，通过奖励模型（Reward Model, RM）对生成图像进行偏好建模，再利用 RL 优化生成模型，从而实现更好的语义一致性与用户对齐。

## 2 文本生成图像的强化学习问题建模

文本生成图像可以被形式化为一个马尔可夫决策过程（Markov Decision Process, MDP）：

状态（State,  $s$ ）：

给定的文本 prompt，以及扩散过程中的中间图像表示。

在扩散模型中，状态可以是不同噪声水平下的潜在图像。例如，在 Stable Diffusion 中，初始状态是随机高斯噪声，逐步去噪接近真实图像。

动作（Action,  $a$ ）：

模型在每一步扩散过程中的预测结果（如噪声预测向量）。

在基于 Transformer 的生成器中，动作也可以定义为生成下一步的潜在特征。

环境（Environment, E）：

生成过程本身（扩散迭代或自回归生成）。环境将模型的动作作用在状态上，得到新的状态。

奖励函数（Reward, R）：

衡量生成图像质量的信号，可来自：

自动指标：如 CLIPScore，评估语义一致性。

美学模型：如 Aesthetic Score。

人类偏好数据：如 Pick-a-Pic，通过成对比较收集用户偏好。

统一奖励模型（UnifiedReward）：基于多模态大模型（如 Qwen-VL），同时考虑语义、细节、美学。

数学上，该问题的目标是最大化期望奖励：

$$J(\theta) = \mathbb{E}_{s, a \sim \pi_\theta}[R(s, a)]$$

其中  $\pi_\theta$  表示参数为  $\theta$  的生成策略（如扩散模型）， $R(s, a)$  为奖励信号。

在具体优化中，可以采用策略梯度（Policy Gradient）的形式：

$$\nabla_\theta J(\theta) \approx \mathbb{E}_{s, a \sim \pi_\theta}[\nabla_\theta \log \pi_\theta(a|s) \cdot R(s, a)]$$

这为后续结合 PPO、DPO 等优化方法 奠定了理论基础。

## 3 文生图强化学习框架

### 3.1. DanceGRPO

#### 3.1.1 提出问题

在视觉生成任务中，扩散模型（Diffusion Models）与整流流（Rectified Flows）已成主流，但在其上稳定引入强化学习（RL）仍面临三项关键挑战：

(1) 与 ODE 采样的不兼容性。 Rectified Flow 的采样基于常微分方程

（ODE），其确定性过程与 RL 中以马尔可夫决策过程（MDP）为基础的“多

轨迹随机探索”天然不匹配，难以进行有效的策略优化。

(2) 大规模训练的不稳定性。现有 RL 方法（如 DDPO、DPOK）在小规模数据集（<100 prompts）尚可运行，但在更大规模数据上易不稳定甚至发散，限制了真实场景落地。

(3) 缺乏视频生成验证。以往工作多集中在文本生成图像（T2I），而对文本生成视频（T2V）与图像生成视频（I2V）的验证稀缺。视频生成不仅需语义一致，还需时间一致性与运动质量，现有方法难以兼顾。

### 3.1.2 解决思路

DanceGRPO<sup>[1]</sup> 针对上述挑战提出统一框架，其核心贡献为：

(1) 统一采样为随机过程。将扩散与整流流的采样过程改写为随机微分方程（SDE），引入必要随机性，使之与 RL 的轨迹采样兼容。

(2) 引入 GRPO 提升稳定性。采用 Group Relative Policy Optimization（GRPO）替代 PPO/DPO，通过组内优势归一化缓解奖励尺度差异，显著提升大规模训练稳定性。

(3) 跨任务统一验证。在 T2I / T2V / I2V 三类任务上统一验证同一 RL 框架，证明通用性与可扩展性。

### 3.1.3 方法

(1) 去噪过程的 MDP 建模

将扩散/整流流的去噪过程形式化为马尔可夫决策过程（MDP）：

$$s_t \triangleq (c, t, z_t), \pi(a_t | s_t) \triangleq p(z_{t-1} | z_t, c)$$

奖励只在最终时刻计算：

$$R(s_t, a_t) = \begin{cases} r(z_0, c), & t = 0 \\ 0, & \text{otherwise} \end{cases}$$

其中， $c$  为文本 prompt， $a_t$  表示由  $z_t$  生成  $z_{t-1}$ ，奖励仅在最终时刻  $t=0$  计算。




图 1 在不同奖励下 Stable Diffusion / FLUX / HunyuanVideo 的性能曲线。

(2) 采样过程统一为 SDE

扩散模型反向过程：

$$dz_t = \left( f_t z_t - \frac{1 + \epsilon_t^2}{2} g_t^2 \nabla \log p_t(z_t) \right) dt + \epsilon_t g_t dw$$

Rectified Flow 反向过程：

$$dz_t = \left( u_t - \frac{1}{2} \epsilon_t^2 \nabla \log p_t(z_t) \right) dt + \epsilon_t dw$$

通过公式将两类模型统一为带随机性的轨迹生成过程，从而支持基于 GRPO 的策略优化与稳定学习。




图 2 对比 DDPO 在 Rectified Flow 上的发散 vs. DanceGRPO 的稳定收敛

(3) GRPO 优化目标

DanceGRPO 的优化目标：

$$J(\theta) = \mathbb{E}_{\{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|c)} \left[ \frac{1}{G} \sum_{i=1}^G \frac{1}{T} \sum_{t=1}^T \min(\rho_{t,i} A_i, \text{clip}(\rho_{t,i}, 1 - \epsilon, 1 + \epsilon) A_i) \right]$$

其中：

$$\rho_{t,i} = \frac{\pi_{\theta}(a_{t,i} | s_{t,i})}{\pi_{\theta_{\text{old}}}(a_{t,i} | s_{t,i})}, \quad A_i = \frac{r_i - \text{mean}(\{r_1, \dots, r_G\})}{\text{std}(\{r_1, \dots, r_G\})}$$

实现要点：

在同一 `prompt` 的组内进行优势归一化，缓解样本间奖励尺度差异，训练更稳定。

不强制使用 *KL* 正则（实验表明收益有限），进一步提高效率。

### 3.1.4 实验结果

#### (1) 文本生成图像（Stable Diffusion v1.4）

表 1 文本生成图像的主客观指标对比

| 模型               | HPS-V2.1 ↑ | CLIP Score ↑ | PICK-A-PIC ↑ | GENEVAL ↑ |
|------------------|------------|--------------|--------------|-----------|
| Stable Diffusion | 0.239      | 0.363        | 0.202        | 0.421     |
| + HPS            | 0.365      | 0.380        | 0.217        | 0.521     |
| + HPS & CLIP     | 0.335      | 0.395        | 0.215        | 0.522     |

结论：引入 DanceGRPO 后，HPS 提升约 52%，CLIP Score 同步提升，图像更符合人类偏好。

#### (2) 文本生成视频（HunyuanVideo）

表 2 文本生成视频指标对比

| 模型        | VQ ↑ | MQ ↑         | TA ↑ | VisionReward ↑ |
|-----------|------|--------------|------|----------------|
| Baseline  | 4.51 | 1.37         | 1.75 | 0.124          |
| DanceGRPO | 7.03 | 3.85 (+181%) | 1.59 | 0.128          |

结论。运动质量（MQ）提升 181%，视觉质量（VQ）提升 56%，时序一致性显著改善。

#### (3) 图像生成视频（SkyReels-I2V）

在 VideoAlign Motion Quality 指标上提升 +91%；

在给定图像条件下，运动真实性显著提高。




图 3 SkyReels-I2V 的运动质量曲线

### 3.1.5 小结

DanceGRPO 通过 SDE 统一采样与组内优势归一化的 GRPO，解决了 ODE 采样与 RL 不兼容、规模化训练不稳定，以及缺乏视频验证三大难题。在 T2I/T2V/I2V 三任务上取得稳定收益，证明了其通用性、可扩展性与工程可落地性。

相较于 DDPO、DPOK、ReFL、DPO，DanceGRPO 具备以下优势（见 Table 1）：

- (1) 首次支持视频生成任务。
- (2) 能扩展至大规模数据集（>10,000 prompts）。
- (3) 在多指标上显著提升 reward（最高 +181%）。
- (4) 原生兼容 Rectified Flow。
- (5) 不依赖可微分 reward，降低显存与实现难度。

## 3.2 Flow-GRPO

### 3.2.1 存在的问题

在文本生成图像任务中，Flow Matching 模型（如 Flow Matching Diffusion）作为一种高效替代扩散模型的新范式，逐渐受到关注。但它在与强化学习结合时面临以下问题：

**PPO 依赖价值网络：**传统 RLHF（如 PPO）需要单独训练 critic 网络来近似价值函数，计算开销大且稳定性差。

**信用分配困难：**图像奖励稀疏（仅在生成终点给分），难以在中间采样步骤进行合理 credit assignment。

**KL 控制复杂：**现有方法多采用经验式 KL 正则，缺乏统一稳定的公式化实现。

**训练效率低：**在大模型（如 SD3.5-M）上进行 RL 优化时，收敛速度慢。

### 3.2.2 解决的问题

Flow-GRPO<sup>[2]</sup> 提出了一种直接作用于 flow matching 模型的 Group Relative Policy Optimization (GRPO)，主要解决：

绕过 critic 网络：通过组归一化优势估计（group-relative advantage），避免训练价值网络；

高效信用分配：利用 group 内 reward 归一化机制，使奖励更稳定，降低方差；

理论化 KL 正则：给出 闭式 KL 公式，在连续时间 SDE/ODE 框架下保证稳定性；

效率提升：在相同训练步数下，比 PPO 收敛更快，且提升生成质量。

### 3.2.3 方法（公式与图）

#### (1) 策略优化目标

Flow-GRPO 的目标函数为：

$$J_{\text{GRPO}}(\theta) = \mathbb{E}_{q, \{o_i\}} \left[ \frac{1}{G} \sum_{i=1}^G \min(\rho_i A_i, \text{clip}(\rho_i, 1 - \varepsilon, 1 + \varepsilon) A_i) \right]$$

其中：

$$\rho_i = \frac{\pi_{\theta}(o_i | q)}{\pi_{\theta_{\text{old}}}(o_i | q)}$$

$$A_i = \frac{r_i - \mu(r)}{\sigma(r)}$$

这种组归一化优势，保证了 reward 方差可控。

#### (2) Flow Matching 框架下的采样更新

Flow 模型由 ODE 表示：

$$\frac{dx}{dt} = v_{\theta}(x, t)$$

在 GRPO 下，将其改写为等价的 SDE 形式：

$$dx = v_{\theta}(x, t)dt + \sigma_t dW_t$$

其中

$\sigma_t$  为噪声项， $W_t$  为布朗运动。这样既保持可微性，又能支持多样性采样。

#### (3) KL 正则闭式解

Flow-GRPO 给出了 KL 正则的解析式（论文 Eq.9）：

$$KL(\pi_{\theta} \parallel \pi_{\text{ref}}) = \frac{1}{2} \int_0^1 \frac{\|v_{\theta}(x, t) - v_{\text{ref}}(x, t)\|^2}{\sigma_t^2} dt$$

相比 PPO 的经验式 KL，Flow-GRPO 的闭式形式可直接计算，稳定性更高。




图 4 Flow-GRPO 框架图，展示了 ODE/SDE 转换与奖励计算流程

### 3.2.4 实验结果

#### 实验设置

模型：SD3.5-M (Medium)

数据集：Pick-a-Pic, PartiPrompts, DrawBench

表 3 Flow-GRPO 结果

| 方法               | PickScore $\uparrow$ | HPSv2 $\uparrow$   | GenEval $\uparrow$ | 训练效率        |
|------------------|----------------------|--------------------|--------------------|-------------|
| SFT baseline     | 0.245                | 0.351              | 0.512              | 1.0×        |
| PPO              | 0.253                | 0.357              | 0.519              | 0.5×        |
| <b>Flow-GRPO</b> | <b>0.264 (+8%)</b>   | <b>0.366 (+4%)</b> | <b>0.529 (+3%)</b> | <b>1.3×</b> |



### 3.2.5 总结

贡献：

(1) 首次将 GRPO 引入 flow matching 框架，避免 critic 网络，提高训练稳定性。

(2) 提出 KL 正则闭式解，使 RLHF 在连续时间模型中可行。

(3) 在大规模模型（SD3.5-M）上验证有效性，优于 PPO。

局限：

(1) 仍然依赖 reward model（如 PickScore），难以避免奖励偏差；

(2) 只在单一模型上做实验，泛化性有待验证；

(3) 在极端 prompt（长文本或极端构图要求）下，仍可能表现欠佳。

## 3.3 MixGRPO

### 3.3.1 提出问题

(1) 现有基于 GRPO 的 Flow 模型（如 Flow-GRPO、DanceGRPO）通常在全部去噪步上以 SDE 采样并优化整条 MDP 轨迹，计算开销大、训练慢。

(2) DanceGRPO 尝试在随机子集步上优化，但子集太小会显著掉点。

(3) 需要一种既保留随机探索又显著降低优化步数的方案，同时不牺牲对奖励计算所需的最终图像质量。

### 3.3.2 解决思路

(1) MixGRPO<sup>[3]</sup>加入了混合 ODE-SDE 采样 + 滑动窗口调度：仅在滑动窗内若干步使用 SDE（引入随机性并进行 GRPO 优化），窗口外全部用 ODE（高效确定性采样），从而把随机性与优化聚焦在少量关键时间步。

(2) 高阶 ODE 求解器加速旧策略采样（ $\pi_{\theta_{\text{old}}}$ ）：窗口之后的 ODE 段不参与比率与梯度，仅影响奖励，可用 DPM-Solver++ 等高阶 ODE 求解器显著降时。

(3) 提出 MixGRPO-Flash：在保证性能接近的同时进一步 71% 降低训练时间。

## 10

## (2) 滑动窗口

定义滑动窗  $W(l) = \{t_l, \dots, t_{l+w-1}\}$ , 只在窗内步做 SDE + GRPO 优化; 窗外全部 ODE。

$$W(l) = \{t_l, t_{l+1}, \dots, t_{l+w-1}\}, \quad l \leq T - w.$$

指数衰减调度（可选）：随窗口右移逐步缩短移动间隔  $\tau$ :

$$\tau(l) = \tau_0 \cdot \exp(-k \cdot \text{ReLU}(l - \lambda_{\text{thr}})).$$

## (3) GRPO 目标（仅在窗口步求和）

MixGRPO 的 GRPO 目标:

$$J_{\text{mixGRPO}}(\theta) = \mathbb{E}_{c \sim \mathcal{C}, \{x_T^i\} \sim \pi_{\theta_{\text{old}}}} \left[ \frac{1}{N} \sum_{i=1}^N \frac{1}{|S|} \sum_{t \in S} \min(r_i^t(\theta) A_i, \text{clip}(r_i^t(\theta), 1 - \varepsilon, 1 + \varepsilon) A_i) \right],$$

$$r_i^t(\theta) = \frac{q_{\theta}(x_{t+1} | x_t, c)}{q_{\theta_{\text{old}}}(x_{t+1} | x_t, c)}, \quad A_i = \frac{R(x_T^i, c) - \text{mean}(\{R(x_T^j, c)\}_{j=1}^N)}{\text{std}(\{R(x_T^j, c)\}_{j=1}^N)}.$$

论文中实验默认  $\varepsilon=10^{-4}$ ; KL 项被去除, 推理时采用混合推理缓解奖励黑客化（附录 A）。

## (4) 高阶 ODE 求解器与 Flash 变体

RF 与  $x_0$ -预测模型关系（用于 DPM-Solver++ 推导）:

$$x_t = tx_1 + (1-t)x_0, \quad v_t = x_1 - x_0, \quad x_0 = x_t - v_t t.$$

二阶多步（Midpoint）修正量  $D_t$  与最终迁移式:

$$D_t \leftarrow \left(1 + \frac{h_t}{2h_{t-1}}\right) \left(x_{t-1} - \frac{v_{\theta}(x_{t-1}, t-1, c)}{t-1} T\right) - \frac{h_t}{2h_{t-1}} \left(x_{t-2} - \frac{v_{\theta}(x_{t-2}, t-2, c)}{t-2} T\right),$$

$$x_t \leftarrow \frac{t}{t-1} x_{t-1} - (1-t)(e^{-h_t} - 1) D_t, \quad 1 \leq t < T,$$

其中  $h_t = \lambda_t - \lambda_{t-1}$ ,  $\lambda_t := \log\left(\frac{1-t}{t}\right)$ 。

理论加速比（Flash/Frozen 策略）:

$$S = \frac{T}{w + (T-w)\tilde{r}}, \quad S_{\text{avg}} = \frac{T}{\mathbb{E}_l[w + l + [(T-w-l)\tilde{r}]]} < \frac{T}{w + (T-w)\tilde{r}}.$$

## 3.3.4 实验结果

（基座：FLUX.1-dev；奖励/指标：HPS-v2.1、PickScore、ImageReward、UnifiedReward；NFE 统计与每迭代耗时，见论文 Table 1）

表 4 训练迭代开销与偏好指标

| 方法                              | $FE_{\pi_{\theta_{old}}}$ | $NFE_{\pi_{\theta}}$ | 迭代耗时(s)↓ | HPS-v2.1<br>↑ | PickScore<br>↑ | ImageReward<br>ard ↑ | UnifiedReward<br>ard ↑ |
|---------------------------------|---------------------------|----------------------|----------|---------------|----------------|----------------------|------------------------|
| FLUX（未调）                        | /                         | /                    | /        | 0.313         | 0.227          | 1.088                | 3.370                  |
| DanceGRPO<br>(25/14)            | 25                        | 14                   | 291.284  | 0.356         | 0.233          | 1.436                | 3.397                  |
| DanceGRPO<br>(25/4)             | 25                        | 4                    | 149.978  | 0.334         | 0.225          | 1.335                | 3.374                  |
| DanceGRPO*<br>(Frozen, 25/4)    | 25                        | 4                    | 150.059  | 0.333         | 0.229          | 1.235                | 3.325                  |
| MixGRPO (25/4)                  | 25                        | 4                    | 150.839  | 0.367         | 0.237          | 1.629                | 3.418                  |
| MixGRPO-Flash<br>(≈16/4)        | 16(Avg)                   | 4                    | 112.372  | 0.358         | 0.236          | 1.528                | 3.407                  |
| MixGRPO-Flash* (8/4,<br>Frozen) | 8                         | 4                    | 83.278   | 0.357         | 0.232          | 1.624                | 3.402                  |

\* Frozen：仅优化最前面的去噪步。

表 5 单/多奖励训练的域内/域外评测（HPDv2 提示集）

| 训练奖励          | 方法        | HPS-v2.1 | CLIP  | PickScore | ImageReward | UnifiedReward |
|---------------|-----------|----------|-------|-----------|-------------|---------------|
| /             | FLUX      | 0.313    | 0.388 | 0.227     | 1.088       | 3.370         |
| HPS-v2.1      | DanceGRPO | 0.367    | 0.349 | 0.227     | 1.141       | 3.270         |
| HPS-v2.1      | MixGRPO   | 0.373    | 0.372 | 0.228     | 1.396       | 3.370         |
| HPS-v2.1+CLIP | DanceGRPO | 0.346    | 0.400 | 0.228     | 1.314       | 3.377         |
| HPS-v2.1+CLIP | MixGRPO   | 0.349    | 0.415 | 0.229     | 1.416       | 3.430         |

### 3.3.5 小结

Mixed ODE-SDE 采样在探索性与方差间取得平衡，解决 Flow-based RL 的效率-稳定性矛盾；

结合 GRPO 的组内优势归一化，进一步提升训练稳定性与样本效率；

在图像生成的人类偏好对齐、美学优化等指标上全面超越 Flow-GRPO，并具备更好的扩展性，适用于大模型与大规模数据训练；

可将 MixGRPO 视为 Flow-GRPO 的效率升级版，与 DanceGRPO 共同完善 RL 在 Flow Matching / Diffusion 系列模型上的统一实践。

### 3.4 TempFlow-GRPO

#### 3.4.1 提出问题

(1) 时间无差别的奖励分配。现有 Flow-GRPO 采用稀疏终端奖励 + 各时间步统一加权，将所有生成步骤等同对待。

(2) 忽视时间步贡献差异。在扩散/流匹配模型中，早期步骤（噪声大）主导全局结构与语义，后期步骤（噪声小）更偏向细节修复与收敛；一视同仁会造成探索效率低、收敛慢/不稳。

(3) 实证提示时序差异显著。论文实验（图 1）显示：仅在单一步注噪时，早期步骤奖励方差明显更高，佐证“时间重要性不均”。

#### 3.4.2 解决思路

(1) 轨迹分叉（Trajectory Branching）。在选定的某一时间步注入随机噪声，其余步骤保持确定性的 ODE 推进，使最终奖励的归因精确落到该时间步，形成时间感知的过程奖励。

(2) 噪声感知加权（Noise-aware Weighting）。按时间步噪声大小分配不同优化权重：噪声大→探索潜力高→权重大；噪声小→权重小，从而抑制“后期步骤主导训练”的现象。

两项机制共同提升探索效率与训练稳定性，解决了统一加权的结构性缺陷。

#### 3.4.3 方法

##### 3.4.3.1 Flow-GRPO 基础（组归一化优势 + 离散采样式）

在组归一化优势（Group-normalized advantage）下，第  $i$  张图在第  $t$  步的优势函数为：

$$\hat{A}_i^t = \frac{R(x_i^0, c) - \text{mean}(\{R(x_j^0, c)\}_{j=1}^G)}{\text{std}(\{R(x_j^0, c)\}_{j=1}^G)}$$

扩散过程采用 ODE/SDE 的离散形式，SDE 注入噪声：

$$x_{t+\Delta t} = x_t + \left[ v_\theta(x_t, t) + \frac{\sigma_t^2}{2t} (x_t + (1-t)v_\theta(x_t, t)) \right] \Delta t + \sigma_t \sqrt{\Delta t} \epsilon$$

其中  $\epsilon \sim \mathcal{N}(0, I)$ ,  $\sigma_t = a\sqrt{\frac{t}{1-t}}$ 。




图 6 仅在单一步注噪时，不同时间步的奖励方差对比

#### 3.4.3.2 Trajectory Branching: 时间步可归因的策略梯度

TempFlow-GRPO<sup>[4]</sup> 在第  $k$  步注入噪声，后续步骤完全采用 ODE 演化，则其策略梯度为：

$$\nabla_{\theta} J(\theta) = \sum_{k=0}^{T-1} \mathbb{E}_{x_T, \epsilon} \left[ \nabla_{\theta} \log p_{\theta}(x_{k+1}|x_k) \hat{A}_k \right]$$

结论：把最终奖励完全归因到第  $k$  步，使得该时间步的优化目标直接受益于奖励信号。论文证明了这是严格有效的信用分配方式。




图 7 奖励标准差（Reward Std）与生成步骤的噪声水平之间的比较分析。两条曲线显示出很强的相关性

#### 3.4.3.3 Noise-aware Weighting: 噪声驱动的时间权重

论文观察到奖励标准差与噪声水平高度相关，因而引入噪声感知的加权重

标函数：

$$J_{\text{policy}}(\theta) = \frac{1}{G} \sum_{i=1}^G \frac{1}{T} \sum_{t=0}^{T-1} \text{Norm}(\sigma_t \sqrt{\Delta t}) \cdot \min(r'_i(\theta) \hat{A}_i^t, \text{clip}(r'_i(\theta), 1-\varepsilon, 1+\varepsilon) \hat{A}_i^t)$$

在该公式中， $\text{Norm}(\sigma_t \sqrt{\Delta t})$  作为权重因子，使早期高噪声步骤获得更大更新幅度，后期低噪声步骤则受到抑制，从而避免了原始 GRPO 中“晚期步骤主导训练”的问题。




图 8 不同权重策略下的奖励方差与收敛曲线对比

### 3.4.4 实验结果

#### 3.4.4.1 Geneval 指标（SD3.5-Medium）

表 6 TempFlow-GRPO vs. Flow-GRPO（Overall）

| 方法                     | 训练步数 | Overall |
|------------------------|------|---------|
| Flow-GRPO（SD3.5-M）     | 5600 | 0.95    |
| Flow-GRPO（SD3.5-M）     | 4400 | 0.9     |
| TempFlow-GRPO（SD3.5-M） | 4400 | 0.97    |

要点: TempFlow-GRPO 在 2000 步左右即可达 0.95，而 Flow-GRPO 需 5600 步，显示显著的训练效率提升。

#### 3.4.4.2 与 SOTA 方法的比较（Geneval）

GPT-4o: 0.84

FLUX.1 Dev: 0.66

SD3.5-M（未优化）：0.63

TempFlow-GRPO（SD3.5-M）：0.97

结论：TempFlow-GRPO 在 Geneval 评测中超过现有强基线与主流大模型。

### 3.4.5 小结

(1) 提出轨迹分叉实现时间可归因的过程奖励；(2) 引入噪声感知加权，让早期高噪声步骤获得更大更新，抑制晚期主导；(3) 在 SD3.5-M 上明显加速收敛并提升性能；(4) 核心思想是把生成过程的物理噪声时序特性与 RL 的奖励分配机制深度结合，突破统一加权的局限，可与 Flow-GRPO/DanceGRPO 形成互补与升级路径。

## 3.5 AR-GRPO 框架分析

### 3.5.1 提出问题

在文本生成图像任务中，自回归（Autoregressive, AR）生成模型（如 MAGVIT、LlamaGen）逐渐受到关注。但在引入 RLHF 时，它们面临以下挑战：

(1) 奖励稀疏与信用分配困难：通常只在最终生成的整张图像上给奖励，难以捕捉逐 token 生成过程中不同决策的重要性。

(2) PPO 等传统方法效率低：需要训练 value 网络，且在离散 token 空间下不稳定。

(3) KL 正则不稳定：在 AR 模型中，token 概率分布偏移导致模式坍缩或探索不足。

(4) 扩展性差：现有 RLHF 方法主要针对扩散模型（如 DPO、GRPO），在 AR 模型上的直接迁移性能不佳。

### 3.5.2 解决思路

AR-GRPO<sup>[5]</sup> 针对以上挑战提出改进：

(1) 无需 value 网络：采用 GRPO（Group Relative Policy Optimization）进



行优势归一化，避免 critic。

(2) 逐 token 优化：通过 autoregressive 序列建模，将奖励信号分解到每个 token，提高 credit assignment。

(3) 闭式 KL 控制：设计了 token-level KL 项，防止训练过程中文本-图像匹配度下降。

(4) 统一框架：将 GRPO 与自回归生成结合，使 RLHF 能够直接优化 AR 图像生成模型。

### 3.5.3 方法

#### (1) 策略目标函数

AR-GRPO 的优化目标为：

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{(x,c) \sim \mathcal{D}, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(c)} \left[ \frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left( \min(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(r_{i,t}(\theta), 1-\epsilon, 1+\epsilon) \hat{A}_{i,t}) - \beta D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) \right) \right]$$

其中：

$$\hat{A}_{i,t} = \frac{r_i - \text{mean}(\{R_i\}_{i=1}^G)}{\text{std}(\{R_i\}_{i=1}^G)},$$

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} \mid c, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid c, o_{i,<t})}.$$

#### (2) KL 正则项

为了避免模式坍塌，AR-GRPO 在 token 级别引入 KL 正则：

$$D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) = \frac{\pi_{\text{ref}}(o_{i,t} \mid c, o_{i,<t})}{\pi_{\theta}(o_{i,t} \mid c, o_{i,<t})} - \log \frac{\pi_{\text{ref}}(o_{i,t} \mid c, o_{i,<t})}{\pi_{\theta}(o_{i,t} \mid c, o_{i,<t})} - 1$$

## 2. 奖励分解

奖励由三个部分构成：

$$R = \lambda_C R_C + \lambda_I R_I + \lambda_R R_R$$

$R_C$ : 对齐度 (text-image alignment, e.g. CLIP score)

$R_I$ : 图像质量 (aesthetic, DeQA)

$R_R$ : 人类偏好相关 (PickScore, UniRwd 等)

$\lambda_c, \lambda_I, \lambda_R$ : 对应权重

### 3.5.4 实验结果

#### (1) ImageNet 条件生成

| Model       | Image Size | IS $\uparrow$ | FID $\downarrow$ | sFID $\downarrow$ | Precision $\uparrow$ | Recall $\uparrow$ |
|-------------|------------|---------------|------------------|-------------------|----------------------|-------------------|
| LlamaGen-B  | 256        | 193.61        | 5.46             | 7.5               | 0.84                 | 0.46              |
| + RL (Ours) | 256        | 211.67        | 5.91             | 8.58              | 0.86                 | 0.4               |
| LlamaGen-B  | 384        | 157.17        | 6.44             | 7.49              | 0.81                 | 0.46              |
| + RL (Ours) | 384        | 195.45        | 7.64             | 8.64              | 0.88                 | 0.34              |
| LlamaGen-L  | 384        | 256.07        | 3.08             | 6.09              | 0.83                 | 0.52              |
| + RL (Ours) | 384        | 264.64        | 4.24             | 5.91              | 0.87                 | 0.44              |
| LlamaGen-XL | 384        | 286.88        | 2.78             | 5.57              | 0.84                 | 0.54              |
| + RL (Ours) | 384        | 293.07        | 3.63             | 5.99              | 0.86                 | 0.48              |

结论: RL 带来 **IS 提升**, 但在 FID / Recall 上有一定下降, 表现出更强的模式偏好但牺牲了多样性。

#### (2) GenEval (文本-图像一致性)

| Model       | PT    | CL   | AB    | CT    | SO   | TO    | Overall |
|-------------|-------|------|-------|-------|------|-------|---------|
| LlamaGen-XL | 0.042 | 0.55 | 0.032 | 0.197 | 0.75 | 0.263 | 0.306   |

|             |      |       |      |       |       |       |       |
|-------------|------|-------|------|-------|-------|-------|-------|
| + RL (Ours) | 0.04 | 0.593 | 0.03 | 0.228 | 0.791 | 0.263 | 0.324 |
|-------------|------|-------|------|-------|-------|-------|-------|

### (3) DrawBench（对齐度 + 人类偏好）

| Model       | CLIP  | HPSv2 | Aesthetic | DeQA  | ImgRwd | PickScore | UniRwd |
|-------------|-------|-------|-----------|-------|--------|-----------|--------|
| LlamaGen-XL | 0.245 | 0.153 | 4.701     | 0.546 | -1.784 | 0.737     | 0.271  |
| + RL (Ours) | 0.274 | 0.208 | 4.808     | 0.551 | -0.712 | 0.769     | 0.312  |

### (4) 消融实验

- KL 正则化作用：加入 KL penalty 后 Recall 稳定，避免模式坍缩。
- 奖励设计作用：仅使用单一奖励效果不佳，融合多奖励（C+I+R）表现最好。

### 3.5.5 小结

贡献：

- (1) 首次将 GRPO 引入 autoregressive 图像生成，避免 critic 网络。
- (2) 在 token-level 建立 KL 正则，提高训练稳定性。
- (3) 在多个基准上超越 PPO，训练效率提升。

局限：

- (1) 仍依赖 reward model，存在偏差问题；
- (2) 目前实验集中在单一 AR 模型（LlamaGen），泛化性未知；
- (3) 对长序列生成（大分辨率图像）仍可能存在 credit assignment 不足。

## 3.6 ReasonGen-R1

### 3.6.1 提出问题

(1) 缺乏显式推理能力：当前自回归图像生成器（如 Janus-Pro、LLaVA-based models）在生成过程中缺少显式的思维链（Chain-of-Thought, CoT）推理，导致在复杂布局、对象交互和语义一致性任务中表现不足。

(2) 训练方式受限：现有训练大多依赖 纯监督学习（SFT）或 直接

RLHF，模型缺乏在生成前进行结构化推理的机制。

(3) 奖励建模不足：现有 RLHF 方法的奖励信号往往是 黑箱式美学分数或 CLIP 分数，缺乏对“推理链条正确性”的直接评估。

### 3.6.2 解决思路

ReasonGen-R1<sup>[6]</sup> 的目标是：

(1) 通过 显式推理数据集，让图像生成模型在生成前学会“思维链”规划。

(2) 在 SFT + RL (GRPO) 的两阶段框架下，将推理链纳入训练范式，从而提升 对象布局合理性、语义一致性和人类偏好。

(3) 提供一个可扩展的 推理-生成统一范式，在文本到图像 (T2I) 和文本到视频 (T2V) 中均表现优异。

### 3.6.3 方法

(1) 策略优化目标 (GRPO)

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{(x,c) \sim \mathcal{D}, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|c)} \left[ \frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left( \min(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(r_{i,t}(\theta), 1-\epsilon, 1+\epsilon) \hat{A}_{i,t}) - \beta D_{\text{KL}}(\pi_{\theta} \| \pi_{\text{ref}}) \right) \right],$$

其中：

$$r_i = \frac{\pi_{\theta}(r, o | q)}{\pi_{\theta_{\text{old}}}(r, o | q)}, \quad \hat{A}_i = \frac{R(o) - \mu(R)}{\sigma(R)}$$

(2) 自适应熵损失

自适应熵损失设定了一个目标熵。在训练过程中，熵损失系数将通过梯度下降自动更新。

$$\mathcal{L}_{\alpha} = \mathbb{E}_{a \sim \pi} \left[ \alpha \cdot (\log \pi(o_{i,t} | q, o_{i,<t}) + \mathcal{H}_{\text{target}}) \right], \quad \alpha = \arcsin(\phi)$$

$\alpha$  是可学习熵损失项， $\mathcal{H}_{\text{target}}$  代表目标熵， $\log \pi(o_{i,t} | q, o_{i,<t})$  代表机器人学习中以当前状态为条件的当前动作输出的熵。

### 3.6.4 实验结果

GenEval benchmark

| Method                     | Single<br>Obj. | Two<br>Obj. | Counting | Colors | Position | Color<br>Attri. | Overall<br>↑ |
|----------------------------|----------------|-------------|----------|--------|----------|-----------------|--------------|
| Janus-Pro-7B<br>(Baseline) | 0.99           | 0.89        | 0.59     | 0.9    | 0.79     | 0.66            | 0.8          |
| ReasonGen-R1<br>(Ours)     | 0.99           | 0.94        | 0.62     | 0.9    | 0.84     | 0.84            | 0.86         |

DPG-Bench

| 模型                     | Global<br>↑ | Entity<br>↑ | Attribute<br>↑ | Relation<br>↑ | Other<br>↑ | Overall<br>↑ |
|------------------------|-------------|-------------|----------------|---------------|------------|--------------|
| Janus-Pro-7B (基<br>线)  | 86.9        | 88.9        | 89.4           | 89.32         | 89.48      | 84.19        |
| REASONGEN-R1<br>(Ours) | 91.66       | 90.92       | 90.72          | 90.62         | 87.49      | 85.88        |

T2I-Benchmark

| 模型                     | Color<br>↑ | Shape<br>↑ | Texture<br>↑ | Spatial<br>↑ | Non-<br>Spatial ↑ | Complex<br>↑ |
|------------------------|------------|------------|--------------|--------------|-------------------|--------------|
| Janus-Pro-7B (基<br>线)  | 0.6359     | 0.3528     | 0.4936       | 0.2061       | 0.3085            | 0.3559       |
| REASONGEN-R1<br>(Ours) | 0.8321     | 0.565      | 0.7295       | 0.3007       | 0.3375            | 0.3909       |

### 3.6.5 小结

贡献：

(1) 提出推理增强的图像生成框架：首次将 CoT 显式引入 autoregressive

图像生成任务。

(2) 两阶段优化：结合 SFT（学习推理+生成）与 GRPO（利用奖励信号优化）。

(3) 提升复杂语义生成质量：在 Pick-a-Pic 和 GenEval 上取得显著提升。

(4) 引导模型学习对象-关系-布局的显式推理能力，而非仅依赖隐式语义。

局限：

(1) 生成开销增加：CoT 平均需额外生成 ~35 个 token，推理成本提高。

(2) 奖励依赖：效果依赖奖励模型的可靠性，若奖励偏差大可能引导错误推理。

(3) 适用范围受限：目前主要在 AR 模型上验证，未在扩散模型或混合架构中测试。

(4) 推理真实性不足：CoT 并不保证逻辑严格正确，可能出现虚假的 reasoning token。

### 3.7 T2I-R1

#### 3.7.1 提出问题

(1) 缺乏细粒度推理能力：以往的 RLHF 框架（DDPO、GRPO）大多只关注最终生成结果（CLIP/HPS/美学分数），缺乏 显式的逐步推理。

ReasonGen-R1 引入了 CoT，但其 推理链仅限于语义层面（高层次的布局、对象交互），缺乏对 token-level 细节生成的约束。

(2) 推理与生成不匹配：单一的语义级推理链容易和图像生成 token 序列脱节，导致推理合理但生成图像仍不符合预期。

(3) 奖励信号不足：现有奖励大多是 CLIP 相似度或美学分数，无法覆盖推理链的语义合理性 + token 级生成一致性。

#### 3.7.2 解决思路

T2I-R1<sup>[7]</sup> 的目标是：

双层次推理 (Dual-level CoT)：

语义级 CoT：在图像生成前，先生成对象关系、属性、布局的高层次

reasoning。

**token 级 CoT:** 在生成过程中，每个图像 token 都结合上下文与语义约束进行微推理。

**协作式优化:** 通过联合奖励函数，将语义 CoT 与 token CoT 结合，引导模型在全局和局部两个层面提升图像质量。

**细粒度奖励:** 结合图像整体奖励与 token 级别奖励，改进了传统 RLHF 的 credit assignment 问题。

### 3.7.3 方法

#### (1) 策略建模

由于我们的方法中存在两种类型的 CoT，首先是语义级 CoT，然后是标记级 CoT。每个响应  $o_i$  由两部分组成，即  $o_i = (s_i, t_i)$ 。从这个意义上说，

$r_{i,j}(\theta)$  被转换为：

$$r_{i,j}(\theta) = \frac{\pi_{\theta}(o_{i,j} | q, o_{i,<j})}{\pi_{\theta_{\text{old}}}(o_{i,j} | q, o_{i,<j})} = \begin{cases} \frac{\pi_{\theta}(s_{i,j} | q, s_{i,<j})}{\pi_{\theta_{\text{old}}}(s_{i,j} | q, s_{i,<j})}, & 0 \leq j \leq |s_i| \\ \frac{\pi_{\theta}(t_{i,j} | q, s_i, t_{i,<j})}{\pi_{\theta_{\text{old}}}(t_{i,j} | q, s_i, t_{i,<j})}, & |s_i| < j \leq |s_i| + M \end{cases}$$

奖励模型的另一种选择是对象检测器，检测模型接受图像和对象查询作为输入，并输出检测到的对象的空间位置和置信度分数。对象检测器  $R_{\text{Det}}$  的奖励确定为：

$$\mathcal{R}_{\text{Det}} = \begin{cases} \alpha R_{\text{spatial}} + (1 - \alpha) \frac{1}{K} \sum_{i=1}^K \mathbb{I}(\text{obj}_i \text{ detected}), & \text{if spatial relationship in prompt} \\ \frac{1}{n} \sum_{i=1}^n \mathbb{I}(n_{\text{obj}_i} = \hat{n}_{\text{obj}_i}), & \text{if number in prompt} \\ \frac{1}{n} \sum_{i=1}^n \mathbb{I}(\text{obj}_i \text{ detected}), & \text{else} \end{cases}$$

可视化问答模型(VQA):

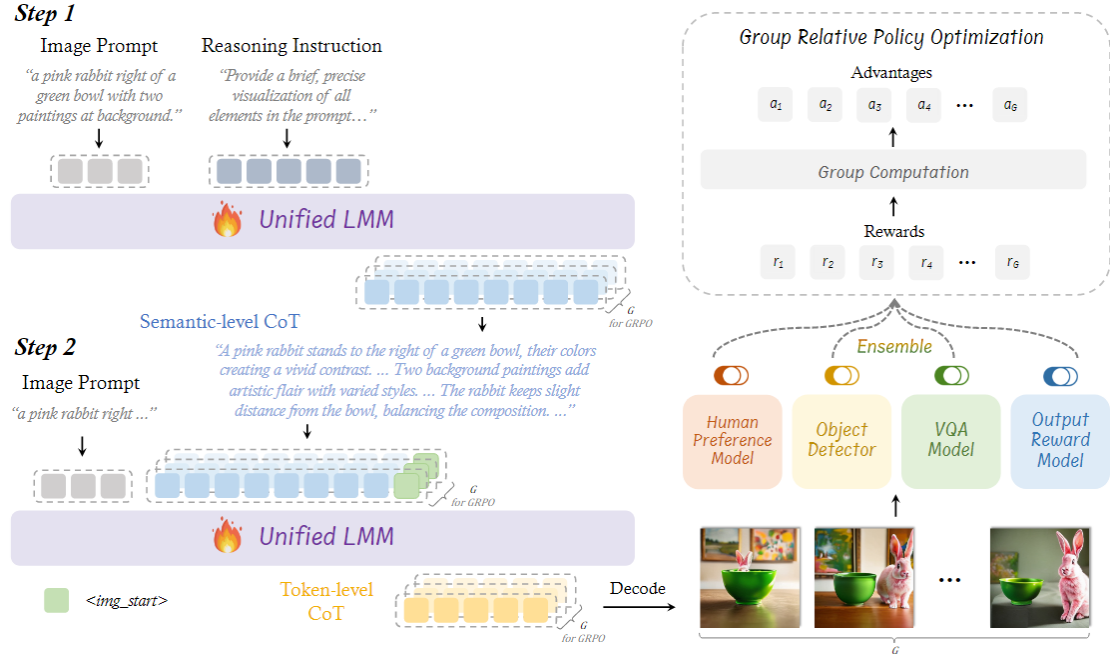
$$\mathcal{R}_{\text{VQA}} = \frac{1}{K} \sum_i \frac{P_{\text{Yes}}^i}{P_{\text{Yes}}^i + P_{\text{No}}^i}$$

#### (2) 优化目标

$$J_{\text{GRPO}}^l(\theta) = \mathbb{E}_{q, r^l, o} \left[ \min(\rho^l A^l, \text{clip}(\rho^l, 1 - \varepsilon, 1 + \varepsilon) A^l) - \beta D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}}) \right], \quad l \in \{s, t\}$$

### (3) 框架图

在步骤 1 中，我们指示模型根据图像提示生成语义级 CoT。在步骤 2 中，图像的生成以图像提示和语义级 CoT 为条件，中间生成过程作为令牌级 CoT。由视觉专家合奏对生成的图像进行评估以获得奖励。我们从每个提示生成  $N$  张图像来计算组相关奖励并执行 GRPO 训练。



### 3.7.4 实验结果

| 模型                    | Attribute Binding |            |              | Object Relationship |                  | Complex<br>↑ |
|-----------------------|-------------------|------------|--------------|---------------------|------------------|--------------|
|                       | Color<br>↑        | Shape<br>↑ | Texture<br>↑ | Spatial<br>↑        | Non-Spatial<br>↑ |              |
| FLUX.1 (扩散)           | 0.7407            | 0.5718     | 0.6922       | 0.2863              | 0.3127           | 0.3703       |
| Janus-Pro-7B (基线, AR) | 0.6359            | 0.3528     | 0.4936       | 0.2061              | 0.3085           | 0.3559       |
| T2I-R1 (Ours, AR)     | 0.813             | 0.5852     | 0.7243       | 0.3378              | 0.309            | 0.3993       |



表 A: T2I-CompBench (主文 Table 1, 摘录 AR 模型 + 代表性扩散模型)

T2I-R1 在 6 个子任务中 **5 项领先**, 其中 **Spatial=0.3378** 较之前 SOTA 高 5%+

表 B: WISE

| 模型                       | Cultural<br>↑ | Spatio-<br>Temporal:<br>Time ↑ | Spatio-<br>Temporal:<br>Space ↑ | Natural<br>Science:<br>Biology ↑ | Physi<br>cs ↑ | Chemi<br>stry ↑ | Overall |
|--------------------------|---------------|--------------------------------|---------------------------------|----------------------------------|---------------|-----------------|---------|
| FLUX.1-dev<br>(扩散)       | 0.48          | 0.58                           | 0.62                            | 0.42                             | 0.51          | 0.35            | 0.5     |
| Janus-Pro-7B<br>(基线, AR) | 0.3           | 0.37                           | 0.49                            | 0.36                             | 0.42          | 0.26            | 0.35    |
| T2I-R1<br>(Ours, AR)     | 0.56          | 0.55                           | 0.63                            | 0.54                             | 0.55          | 0.3             | 0.54    |

### 3.7.5 小结

贡献:

(1) 双层次推理框架: 首次在文本生成图像任务中联合语义级 CoT 与 token 级 CoT。

(2) 细粒度奖励优化: 改进了 RLHF 中的稀疏奖励问题, 实现更精准的 credit assignment。

(3) 显著性能提升: 在多个 benchmark 上超过 ReasonGen-R1 与 AR-

GRPO。

(4) 增强语义一致性：提升了多对象、复杂关系与细节生成能力。

局限：

(1) 训练复杂度高：双层次推理与奖励增加了训练成本。

(2) 推理开销增加：CoT 生成 token 显著增加计算负担。

(3) 奖励依赖问题仍存在：若奖励模型不可靠，可能引导错误优化。

(4) 适用性未广泛验证：目前主要针对 AR 模型，未在扩散或 flow-based 模型中测试。

## 4 参考文献

- [1] XUE Z, WU J, GAO Y, 等. DanceGRPO: Unleashing GRPO on visual generation[A/OL]. arXiv, 2025[2025-07-28]. <http://arxiv.org/abs/2505.07818>. DOI:10.48550/arXiv.2505.07818.
- [2] LIU J, LIU G, LIANG J, 等. Flow-GRPO: Training flow matching models via online RL[A/OL]. arXiv, 2025[2025-08-01]. <http://arxiv.org/abs/2505.05470>. DOI:10.48550/arXiv.2505.05470.
- [3] LI J, CUI Y, HUANG T, 等. MixGRPO: Unlocking flow-based GRPO efficiency with mixed ODE-SDE[A/OL]. arXiv, 2025[2025-08-16]. <http://arxiv.org/abs/2507.21802>. DOI:10.48550/arXiv.2507.21802.
- [4] HE X, FU S, ZHAO Y, 等. TempFlow-GRPO: When timing matters for GRPO in flow models[A/OL]. arXiv, 2025[2025-08-16]. <http://arxiv.org/abs/2508.04324>. DOI:10.48550/arXiv.2508.04324.
- [5] YUAN S, LIU Y, YUE Y, 等. AR-GRPO: Training autoregressive image generation models via reinforcement learning[A/OL]. arXiv, 2025[2025-08-16]. <http://arxiv.org/abs/2508.06924>. DOI:10.48550/arXiv.2508.06924.
- [6] ZHANG Y, LI Y, YANG Y, 等. ReasonGen-R1: CoT for autoregressive image generation models through SFT and RL[A/OL]. arXiv, 2025[2025-07-28]. <http://arxiv.org/abs/2505.24875>. DOI:10.48550/arXiv.2505.24875.

[7] JIANG D, GUO Z, ZHANG R, 等. T2I-R1: Reinforcing image generation with collaborative semantic-level and token-level CoT[A/OL]. arXiv, 2025[2025-07-28]. <http://arxiv.org/abs/2505.00703>. DOI:10.48550/arXiv.2505.00703.